КОМПЬЮТЕРНОЕ ЗРЕНИЕ · 1 КУРС МАГИСТРАТУРЫ

Практическая работа № 4

Генеративно-состязательные сети (GAN)
Генерация изображений CIFAR-10

ПРЕДВАРИТЕЛЬНЫЙ ОТЧЕТ

Выполнила	Бахорина Ольга Александровна
Группа	R4176c
Уровень	1 курс магистратуры
Версия	Предварительная, до FULL-запуска
Дата	13 сентября 2026 г.

Документ описывает реализованный pipeline и методологию. Фактические метрики и визуальные результаты намеренно не приводятся, поскольку notebook еще не выполнен в полном режиме.

РАЗДЕЛ 01

Паспорт работы и статус готовности

> СТАТУС НА МОМЕНТ ПОДГОТОВКИ ОТЧЕТА
>
> В notebook реализованы загрузка CIFAR-10, Vanilla GAN, DCGAN, обучение, визуализации, latent interpolation и расчет FID/IS. Однако все 23 кодовые ячейки не имеют сохраненных outputs, а конфигурация по умолчанию содержит `FAST_MODE = True`. Следовательно, завершенные экспериментальные результаты пока отсутствуют.

Цель

Изучить принципы генеративно-состязательного обучения на задаче генерации изображений и сопоставить полносвязную Vanilla GAN со свёрточной DCGAN на CIFAR-10.

Задачи

- загрузить и нормализовать CIFAR-10 в диапазон `[-1, 1]`;
- реализовать генератор и дискриминатор для Vanilla GAN и DCGAN;
- обучить модели в сопоставимых условиях и записать `loss_G` и `loss_D`;
- получить сетки 8 x 8, snapshots по эпохам и latent interpolation;
- оценить модели по FID, Inception Score, времени и числу параметров;
- сформулировать выводы только по фактическому FULL-запуску.

Матрица соответствия заданию

Требование	Реализовано в коде	Подтверждено результатом
CIFAR-10 и нормализация	Да	Нет: outputs отсутствуют
Vanilla GAN	Да	Нет: обучение не сохранено
DCGAN	Да	Нет: обучение не сохранено
Динамика loss	Да, логируется каждый шаг	Нет графиков запуска
Сетки и interpolation	Да	Нет изображений запуска
FID и Inception Score	Да, через torch-fidelity	Нет численных значений

Опциональные WGAN-GP, Conditional GAN, StyleGAN2-ADA, VAE/DDPM и Precision/Recall не входят в обязательный минимум и в текущую реализацию не включены.

РАЗДЕЛ 02

Теоретические основы GAN

Состязательная постановка

GAN объединяет две модели. Генератор G преобразует случайный латентный вектор z в синтетическое изображение G(z). Дискриминатор D получает реальное или синтетическое изображение и оценивает, к какому источнику оно относится. Обучение образует игру: D улучшает распознавание подделок, а G учится создавать изображения, которые D принимает за реальные.

КЛАССИЧЕСКАЯ ЦЕЛЕВАЯ ФУНКЦИЯ

```
min_G max_D E_x[log D(x)] + E_z[log(1 - D(G(z)))]
```

В notebook дискриминатор возвращает logit, а sigmoid и бинарная кросс-энтропия объединены в численно устойчивой функции `BCEWithLogitsLoss`.

Роли основных компонентов

Компонент	Назначение	Критичный риск
Латентное пространство	Источник случайности: z ~ N(0, I), размерность 128	Слабая структура переходов
Генератор	Отображение latent vector в RGB-изображение 32 x 32	Mode collapse или артефакты
Дискриминатор	Различение real/fake через один logit	Слишком быстрое доминирование
Adversarial loss	Сигнал для одновременной оптимизации G и D	Осцилляции и нестабильность

Почему одной функции потерь недостаточно

GAN loss показывает баланс двух игроков, но не измеряет напрямую реалистичность и разнообразие. Низкое значение loss одной сети может означать как прогресс, так и нарушение баланса. Поэтому вывод строится по трем группам свидетельств: кривым обучения, визуальным результатам и количественным метрикам FID/IS.

Vanilla GAN и DCGAN

Свойство	Vanilla GAN	DCGAN
Представление изображения	Плоский вектор 3072	Тензор с пространственными осями
Основные слои	Linear	ConvTranspose2d / Conv2d
Пространственная структура	Явно не учитывается	Сохраняется иерархией сверток
Ожидаемый профиль	Простой baseline	Более подходящий inductive bias для изображений

РАЗДЕЛ 03

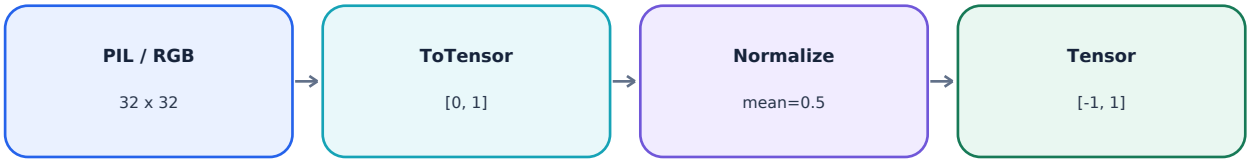
Данные и предобработка

CIFAR-10

CIFAR-10 содержит 60 000 цветных изображений размером 32 x 32 пикселя. Официальное разбиение включает 50 000 training images и 10 000 test images. Набор содержит десять классов: самолет, автомобиль, птица, кошка, олень, собака, лягушка, лошадь, корабль и грузовик.

Характеристика	Значение	Использование
Формат	RGB, 3 x 32 x 32	Вход D и выход G
Training split	50 000 изображений	Обучение без class labels
Test split	10 000 изображений	Фиксированный real set для FID
Классы	10, сбалансированные	Проверка состава, не conditioning

Pipeline преобразований



Преобразование `Normalize((0.5, 0.5, 0.5), (0.5, 0.5, 0.5))` согласовано с Tanh генератора. Для отображения используется обратное преобразование `x_display = clamp(0.5*x + 0.5, 0, 1)`.

Разбиение и воспроизводимость

- GAN оптимизируется только по training split; test split не участвует в обучении;
- фиксируется seed = 42 для Python, NumPy, PyTorch и DataLoader;
- для сравнения моделей DataLoader возвращается к тому же seed;
- в debug-режиме подмножество из 2048 training images выбирается воспроизводимо;
- распределение классов и сетка 16 реальных изображений должны быть сохранены в финальном запуске.

> МЕТОДОЛОГИЧЕСКОЕ ОГРАНИЧЕНИЕ
>
> Поскольку GAN безусловная, class labels не передаются моделям. Равномерный исходный набор не гарантирует, что генератор воспроизведет классы одинаково часто. Этот аспект оценивается по разнообразию фактических samples.

РАЗДЕЛ 04

Архитектура Vanilla GAN

Генератор



Выходной вектор преобразуется к форме 3 x 32 x 32. Между полносвязными слоями применяются ReLU, а после слоев на 512 и 1024 признака - BatchNorm1d. Финальный Tanh ограничивает значения диапазоном [-1, 1].

Дискриминатор



После первых двух Linear-слоев используются LeakyReLU(0.2) и Dropout(0.3). Sigmoid отсутствует, поскольку модель обучается с BCEWithLogitsLoss.

Размерность и обучаемые параметры

Часть	Последовательность	Обучаемые параметры
Generator	128 -> 256 -> 512 -> 1024 -> 3072	3 841 792
Discriminator	3072 -> 1024 -> 512 -> 1	3 672 065
Итого	G + D	7 513 857

Число параметров вычислено аналитически по объявленным слоям и не является метрикой качества. В финальной версии оно должно быть подтверждено runtime-функцией `count_parameters`.

Ожидаемые свойства baseline

- простая реализация и единый векторный интерфейс;
- значительная доля параметров сосредоточена в переходе 1024 -> 3072;
- отсутствует встроенное представление локальных соседств пикселей;
- архитектура чувствительна к нестабильности состязательного обучения.

РАЗДЕЛ 05

Архитектура DCGAN

Генератор



Первые три ConvTranspose2d-блока используют BatchNorm2d и ReLU. Пространственное разрешение последовательно увеличивается 1 -> 4 -> 8 -> 16 -> 32.

Дискриминатор



Во всех скрытых блоках применяется LeakyReLU(0.2). Первый Conv2d-блок обходится без BatchNorm, а последний возвращает единственный logit и разворачивается до формы N x 1.

Инициализация и параметры

Объект	Правило	Обучаемые параметры
Conv / ConvTranspose	weights ~ N(0, 0.02)	В составе G и D
BatchNorm	scale ~ N(1, 0.02), bias = 0	В составе G и D
Generator	4 ConvTranspose2d-блока	1 183 616
Discriminator	4 Conv2d-блока	663 296
Итого	G + D	1 846 912

Число параметров является детерминированной характеристикой объявленной архитектуры и должно быть повторно подтверждено runtime-выводом полного запуска.

КЛЮЧЕВОЕ ОТЛИЧИЕ

DCGAN обрабатывает данные как пространственные feature maps. Поэтому модель имеет inductive bias, соответствующий изображениям, и при этом в данной конфигурации содержит примерно в четыре раза меньше обучаемых параметров, чем полносвязная пара G + D. Это архитектурное наблюдение, а не доказательство лучшего FID/IS.

РАЗДЕЛ 06

Протокол обучения

Один шаг оптимизации



Сначала дискриминатор оптимизируется по реальным изображениям и отсоединенным samples генератора. Затем параметры D временно исключаются из вычисления градиентов, создается новый fake batch, и генератор обновляется так, чтобы D относил эти изображения к реальным.

Общие гиперпараметры

Параметр	Значение	Комментарий
Seed	42	Python, NumPy, PyTorch, DataLoader
Latent dimension	128	N(0, I)
Batch size	64	Одинаково для обеих моделей
Оптимизатор	Adam	Отдельный для G и D
Learning rate	2e-4	Одинаково для G и D
Adam betas	(0.5, 0.999)	DCGAN-совместимая настройка
Loss	BCEWithLogitsLoss	Без отдельного Sigmoid
Fixed noise	64 vectors	Одни входы для snapshots

Debug и финальный режим

Режим	Training data	Эпохи	Images для FID/IS	Назначение
FAST/debug	2048	1	1000	Только smoke-check
FULL/final	50 000	100	10 000	Итоговый эксперимент

УСЛОВИЕ ДОСТОВЕРНОСТИ

Сравнение допустимо только после последовательного запуска обеих моделей в FULL-режиме на одном устройстве, с одинаковыми seed, порядком batches, числом эпох, loss и настройками Adam. Результаты FAST/debug нельзя переносить в итоговые выводы.

Сохраняемые артефакты

Pipeline сохраняет checkpoints генератора, дискриминатора и оптимизаторов, историю loss по шагам, snapshots fixed-noise на эпохах 0, 50 и 100, суммарное время обучения и время каждой эпохи. Эти артефакты должны существовать после финального выполнения notebook.

РАЗДЕЛ 07

Методика оценки качества

Три уровня доказательств

Уровень	Материал	Интерпретация
Динамика	loss_G и loss_D по training steps	Баланс и устойчивость, но не абсолютное качество
Визуальный	8 x 8 grids, snapshots, interpolation	Резкость, разнообразие, повторяемость, плавность
Количественный	FID и Inception Score	Распределение признаков и разнообразие predictions
Вычислительный	время, время/эпоху, параметры	Стоимость модели в текущей среде

FID

Fréchet Inception Distance сравнивает средние и ковариации признаков реальных и сгенерированных изображений. Меньшее значение лучше. В notebook real set берется из CIFAR-10 test split, a generated set создается фиксированным seed. Оба набора экспортируются одинаково: RGB PNG, uint8 [0, 255].

Inception Score

Inception Score оценивает сочетание уверенности предсказаний классификатора и разнообразия сгенерированного набора. Большее значение лучше. Поскольку IS не использует real set и CIFAR-10 имеет низкое разрешение, показатель нельзя интерпретировать отдельно от FID и визуальной проверки.

Latent interpolation

ЛИНЕЙНЫЙ ПУТЬ

```
z(alpha) = (1 - alpha) * z1 + alpha * z2, alpha in [0, 1]
```

Десять точек включают обе границы. Обе модели получают одинаковые численные значения latent path; для DCGAN меняется только форма на 128 x 1 x 1.

Правила корректного вывода

- использовать ровно 10 000 real и 10 000 generated images для каждой модели;
- не смешивать quick/debug и full/final в одной сравнительной таблице;
- о mode collapse говорить только при наблюдаемом повторении ограниченного набора шаблонов;
- время сравнивать только в одной аппаратной и программной среде;
- победителя определять по совокупности FID, IS, визуального качества и стоимости.

РАЗДЕЛ 08

Экспериментальный раздел: текущий статус

РЕЗУЛЬТАТЫ ЕЩЕ НЕ ПОЛУЧЕНЫ

На момент формирования документа notebook не содержит outputs ни в одной кодовой ячейке. Фактическое обучение в FULL-режиме, расчет метрик и визуальная оценка не подтверждены. Численные значения ниже не подменяются демонстрационными числами из задания.

Что нельзя утверждать до запуска

Показатель	Vanilla GAN	DCGAN	Причина
Финальный loss_G / loss_D	Не определен	Не определен	История не выполнена
FID	Не определен	Не определен	Нет 10 000 generated samples
Inception Score	Не определен	Не определен	torch-fidelity не запускался
Время обучения	Не определено	Не определено	Зависит от устройства сессии
Визуальное качество	Не оценено	Не оценено	Grids и snapshots отсутствуют
Mode collapse	Не установлен	Не установлен	Нужны фактические samples
Лучшая модель	Не выбрана	Не выбрана	Нет совокупности доказательств

Что должна содержать итоговая версия

- вывод среды: версии библиотек, тип устройства и режим FULL/final;
- таблицу распределения классов и сетку реальных изображений;
- графики loss_G и loss_D для каждой модели и общий сравнительный график;
- сетки 8 x 8 на фиксированном шуме для начала, середины и конца обучения;
- финальную сетку Vanilla GAN рядом с DCGAN;
- два ряда latent interpolation из 10 изображений;
- таблицу FID, IS и IS std по 10 000 generated images;
- время полного обучения, среднее время эпохи и runtime-count параметров;
- содержательный анализ артефактов, разнообразия и возможного mode collapse;
- финальный вывод, сформированный из фактических значений текущей сессии.

ПРИНЦИП ЧЕСТНОЙ ОТЧЕТНОСТИ

Демонстрационные значения FID/IS из методических материалов являются примером формата сравнения и не могут использоваться как результаты данной работы. Итоговый отчет обновляется только после сохраненного воспроизводимого запуска.

РАЗДЕЛ 09

План завершения и критерии приемки

Последовательность финального запуска

Шаг	Действие	Проверка завершения
1	Переключить конфигурацию на FULL	FAST_MODE = False; epochs = 100
2	Выполнить notebook сверху вниз	Нет ошибок и пропущенных ячеек
3	Обучить Vanilla GAN	История, checkpoint и snapshots сохранены
4	Обучить DCGAN	Те же артефакты и общий протокол
5	Оценить обе модели	10 000 real + 10 000 fake на модель
6	Сохранить визуализации	Loss, grids, snapshots, interpolation
7	Проверить выводы	Каждое утверждение опирается на output
8	Собрать итоговый PDF	Метрики, рисунки и интерпретация включены

Критерии приемки результатов

- Notebook полностью выполнен и сохраняет execution counts и outputs;
- FULL/final явно указан в выводе конфигурации;
- обучение использует 50 000 training images и 100 эпох для обеих моделей;
- FID и IS вычислены единым pipeline по 10 000 generated samples на модель;
- все рисунки имеют подписи и сопоставимую шкалу;
- описана динамика loss без отождествления loss с визуальным качеством;
- оценены резкость, разнообразие, повторяемость и плавность interpolation;
- время, параметры и качество сведены в одну итоговую таблицу;
- вывод не содержит демонстрационных или заранее заданных чисел.

Риски воспроизводимости

Риск	Контроль
Различия CPU/GPU	Зафиксировать устройство и версии CUDA/PyTorch
Случайность GAN	Seed 42; при расширении эксперимента - несколько seeds
Скачивание CIFAR-10 / Inception weights	Проверить доступ к сети до длинного запуска
Незакрепленные зависимости	Зафиксировать проверенные версии в окружении сдачи
Потеря runtime-файлов	Сохранить checkpoints и графические артефакты

ГОТОВНОСТЬ К СДАЧЕ

Текущий документ пригоден как методологический черновик. Комплект становится готовым к сдаче только после FULL-запуска, сохранения результатов в notebook и замены предварительного экспериментального раздела фактическими данными.

РАЗДЕЛ 10

Выводы и источники

Предварительные выводы

Реализованный notebook охватывает обязательную техническую часть задания: CIFAR-10, две базовые архитектуры, единый цикл обучения, фиксацию loss, checkpoints, snapshots, latent interpolation и расчет FID/IS через torch-fidelity. Методика сравнения выстроена корректно: модели получают одинаковые условия, а реальные изображения для FID берутся из test split, не участвующего в оптимизации.

По структуре архитектур DCGAN лучше соответствует пространственной природе изображения, а ее объявленная конфигурация содержит меньше параметров, чем полносвязная пара Vanilla GAN. Однако это не доказывает преимущество по качеству. До полного запуска нельзя выбрать лучшую модель, описать mode collapse, привести FID/IS или сравнить время.

ИТОГОВОЕ ЗАКЛЮЧЕНИЕ

Цель работы будет достигнута после воспроизводимого FULL-запуска и доказательного сравнения по фактическим метрикам, графикам и изображениям. До этого момента отчет сохраняет статус предварительного.

Использованные материалы

№	Источник
1	Текст задания: «Практическая работа 4: Генеративно-состязательные сети (GAN). Генерация изображений на примере CIFAR-10»; материал пользователя.
2	Notebook проекта: notebooks/practical_work_4_gan.ipynb; состояние на 13.09.2026.
3	Goodfellow I. et al. Generative Adversarial Nets. NeurIPS, 2014.
4	Radford A., Metz L., Chintala S. Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks. ICLR, 2016.
5	Salimans T. et al. Improved Techniques for Training GANs. NeurIPS, 2016.
6	Heusel M. et al. GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium. NeurIPS, 2017.

Граница применимости документа

Документ не подтверждает завершение эксперимента и не содержит фиктивных показателей. После выполнения notebook требуется обновить экспериментальный раздел фактическими FID/IS, графиками loss, generated grids, snapshots, latent interpolation, временем и содержательными выводами.

Бахорина Ольга Александровна · группа R4176c · 1 курс магистратуры