Практическая работа № 2
Обнаружение объектов

Дисциплина: «Прикладной искусственный интеллект»
Студентка: Бахорина Ольга Александровна
Группа: R4176c · Курс: 1 курс магистратуры

1. Постановка, данные и источник

Задача — обнаружение объектов на микроскопических снимках крови. Требуется локализовать и классифицировать клетки трёх типов.

Набор данных

Blood Cell Detection v3 (BCCD), Team Roboflow, лицензия Public Domain.

Классы (из data.yaml)

class_id	Название	Описание
0	Platelets	Тромбоциты — мелкие безъядерные фрагменты клеток
1	RBC	Эритроциты (красные кровяные тельца)
2	WBC	Лейкоциты (белые кровяные тельца), наиболее крупные

Размеры выборок

Split	Изображений	Аннотаций Platelets	Аннотаций RBC	Аннотаций WBC
train	254	247	2909	262
val	73	76	819	72
test	37	38	425	38
Итого	364	361	4153	372

2. Аудит данных и разбиение

Перед обучением выполнен аудит исходного BCCD v3. Во время аудита найдена одна связанная пара train/test; после визуальной проверки

изображение перенесено из train в test. После исправления размеры выборок составили 254/73/37.

Проверка	Результат
Декодировано изображений	364
Форматы	{'RGB': 364}
Размеры изображений	{'416x416': 364}
Повреждённые/отсутствующие labels	0
Пиксельных дублей (до корректировки)	0
Байтовых дублей (до корректировки)	0
Межвыборочных пар после корректировки	0
Проверено bbox	4 886
Валидация YOLO ↔ xyxy ↔ COCO	passed
Letterbox round-trip	passed
Проверка целостности разбиения	passed
Блокеры	0

Дополнительный screening DCT64 не выявил новых межвыборочных кандидатов после корректировки. Это не подтверждает независимое происхождение всех изображений, а лишь означает, что в рамках проведённой проверки новых совпадений не найдено. Аудит на этом этапе относится только к данным и не включает запуск модели.

3. Архитектуры детекторов

3.1. YOLO26n

Однопроходный детектор. Backbone: последовательность свёрточных блоков Conv+BN+SiLU, C3k2-блоки с bottleneck-соединениями, C3k-блоки с двойными shortcut. Neck: SPPF (spatial pyramid pooling with fixed kernel),

C2PSA с PSABlock (self-attention). FPN-подобная пирамида: upsampling + concat на трёх масштабах (P3/P4/P5). Head: Detect, decoupled heads для bbox и класса, DFL-регрессия смещений.

Параметр	Значение
Архитектура	YOLO26n (DetectionModel)
Параметров всего	2,504,970
Обучаемых параметров	2,504,970
Входное разрешение	640×640
Начальные веса	yolo26n.pt, Ultralytics assets v8.4.0
SHA-256 весов	9b09cc8b...f0fc8a5f...

3.2. Faster R-CNN ResNet50-FPN-v2

Двухэтапный детектор. Backbone: ResNet50 с residual-блоками (conv+BN+ReLU, shortcut-соединения). FPN neck: боковые соединения P2–P5 (4 масштаба). RPN генерирует ~1000 кандидатов-рамок (anchors 3 aspect ratios × 3 sizes на масштаб). RoI Align извлекает признаки для каждого кандидата. Head: 2-слойный MLP классификатор (фон + 3 класса) и bbox-регрессор.

Параметр	Значение
Архитектура	FasterRCNN_ResNet50_FPN_V2
Параметров всего	43,266,403
Обучаемых параметров	43,041,059
Входное разрешение	640×640
Начальные веса	FasterRCNN_ResNet50_FPN_V2_Weights.COCO_V1
SHA-256 весов	dd69338a...
Batch size	2 (ограничение GPU: 7 871 MiB)

4. Матрица опытов и параметры обучения

Все конфигурации: seed=42, fp32, image_size=640, NMS IoU=0.7, score_pr=0.25, matching_iou_pr=0.5, max_detections=100. Метрика выбора checkpoint: максимальный val AP (mAP@0.5:0.95).

Config	Модель	Optimizer	LR	Batch	Epochs	Peak GPU (MiB)
yolo_a	YOLO26n	AdamW	0.001	8	10	2 582
yolo_b	YOLO26n	AdamW	0.0003	8	9	2 582
frcnn_a	FasterRCNN-R50-FPN-v2	SGD	0.005	2	6	7 871

Метрики YOLO26n — конфигурация yolo_a (lr=0.001) по эпохам (val)

Эпоха	Precision	Recall	mAP50	mAP@0.5:0.95
0	0.8178	0.4246	0.4872	0.2711
1	0.9029	0.6026	0.7857	0.4962
2	0.7093	0.8277	0.8872	0.5205
3	0.7739	0.7369	0.8749	0.5299
4	0.8458	0.9167	0.9206	0.5812
5	0.8597	0.8860	0.9083	0.5769
6	0.8851	0.8547	0.9267	0.6034
7	0.8639	0.8691	0.9074	0.5785
8	0.8558	0.9210	0.9150	0.5946
9	0.8505	0.9241	0.9148	0.6123

* Эпоха 9 выбрана как лучшая по val AP (mAP@0.5:0.95 = 0.6323).

Метрики YOLO26n — конфигурация yolo_b (lr=0.0003) по эпохам (val)

Эпоха	Precision	Recall	mAP50	mAP@0.5:0.95
0	0.1044	0.6105	0.4545	0.2790
1	0.8969	0.6222	0.6344	0.4320
2	0.8691	0.7754	0.9183	0.6147
3	0.8111	0.9090	0.9202	0.6144
4	0.8425	0.9079	0.9197	0.6031
5	0.8576	0.9097	0.9252	0.6140
6	0.8493	0.9050	0.9182	0.6078
7	0.8446	0.8924	0.9154	0.6041
8	0.8367	0.9315	0.9161	0.6080

Конфигурация yolo_b не превзошла yolo_a по итоговому val AP. При меньшем LR сходимость была более плавной, но итоговый mAP@0.5:0.95 оказался немного ниже.

5. Итоговые метрики (val, лучший checkpoint)

Показатель	yolo_a	yolo_b	frcnn_a
Модель	YOLO26n	YOLO26n	FasterRCNN-R50
Эпоха	9	5	5
mAP@0.5:0.95	0.6323	0.6282	0.6282
mAP50	0.9275	0.9189	0.9215
AP Platelets	0.4865	0.4887	0.5205
AP RBC	0.6220	0.6218	0.6077
AP WBC	0.7884	0.7741	0.7564

mAP@0.5:0.95 вычислен при IoU∈[0.5, 0.95] с шагом 0.05. Precision/Recall при score_pr=0.25, IoU_pr=0.5. Val использовался только для выбора checkpoint; test не использовался при выборе.

6. Анализ ошибок (FP/FN) и ограничения

6.1. YOLO26n — конфигурация yolo_a (epoch 9)

Platelets (AP=0.487): основной источник ошибок. FP возникают из-за артефактов фона со схожей текстурой, FN — из-за малого размера тромбоцитов и их частичного перекрытия другими клетками. Одноэтапный детектор без специализированных anchor-масштабов хуже обнаруживает объекты <10px.

RBC (AP=0.622): умеренный FP в зонах плотных скоплений эритроцитов — NMS с IoU=0.7 не всегда разрешает перекрытия при взаимном IoU~0.5–0.7. FN редки (клетки крупные и однородные).

WBC (AP=0.788): минимальные ошибки. Крупный размер и характерная многодольчатая форма делают класс легко обнаруживаемым. Наблюдались единичные FP при score~0.91 с IoU=0.13 по GT.

6.2. Faster R-CNN — конфигурация frcnn_a (epoch 5)

Platelets (AP=0.521): RPN с anchor-based подходом предлагает более точные мелкие кандидаты → AP Platelets выше, чем у YOLO26n (+0.034). FP сохраняются при низких score из-за схожести тромбоцитов с фоновыми артефактами.

RBC (AP=0.608): аналогичен YOLO; batch=2 ограничивает статистику градиента, что может объяснять чуть меньший AP по сравнению с yolo_a.

WBC (AP=0.756): ниже YOLO на 0.032, вероятно из-за меньшего числа эпох (6 против 10) и меньшего batch. Системные FP: bbox с score 0.87–0.91 при IoU<0.15 — частично перекрывающиеся RBC.

6.3. YOLO vs Faster R-CNN: принципиальные различия

Аспект	YOLO26n	Faster R-CNN
Этапность	Однопроходный	Двухэтапный (RPN + Head)
Anchors	Anchor-free (DFL)	Anchor-based (9 типов/масштаб)
Скорость	Быстрее	Медленнее
Параметры	2.5M	43.3M
Batch на GPU T4	8	2
Сильные стороны	RBC и WBC	Platelets (мелкие объекты)
Эффект разрешения	640px достаточно	640px ограничивает P2-P5 для 416px нативных изображений

6.4. Ограничения работы

BCCD — небольшой датасет из 364 изображений, поэтому результаты относятся только к этой выборке и указанным условиям оценки (score≥0.25, IoU=0.5). Из-за вычислительного бюджета обучение ограничено 6–10 эпохами на Kaggle T4×2. Test-split не использовался при выборе модели или гиперпараметров; его финальная оценка должна выполняться отдельным запуском.

7. Выводы

По val mAP@0.5:0.95 лучший результат получила конфигурация yolo_a (YOLO26n, epoch 9): mAP@0.5:0.95=0.6323 и mAP50=0.9275 при 2.5M параметров и batch=8.

Faster R-CNN (frcnn_a, epoch 5) показал близкий mAP@0.5:0.95=0.6282, хотя содержит примерно в 17 раз больше параметров. При этом AP класса Platelets у него выше: 0.521 против 0.487 у YOLO26n, что согласуется с преимуществом anchor-based RPN при поиске мелких объектов.

Оба детектора получили mAP50 не ниже 0.92. Лучше всего обнаруживаются WBC (AP 0.756–0.788), а наиболее сложным классом остаются Platelets (AP 0.487–0.521).

Если важны скорость и ограниченные вычислительные ресурсы, предпочтительнее YOLO26n. Faster R-CNN имеет смысл выбирать, когда приоритетом является обнаружение мелких объектов и допустима более высокая вычислительная стоимость.

Сводная таблица

Метрика	yolo_a (best)	frcnn_a
mAP@0.5:0.95 (val)	0.6323	0.6282
mAP50 (val)	0.9275	0.9215
AP Platelets	0.4865	0.5205
AP RBC	0.6220	0.6077
AP WBC	0.7884	0.7564
Параметров	2 504 970	43 266 403
Эпоха	9	5

8. Источники и программное обеспечение

Данные

Параметр	Значение
Датасет	Blood Cell Detection v3 (BCCD)
Источник	Roboflow Universe — Team Roboflow
Лицензия	Public Domain

Начальные веса

Модель	Файл	Источник	SHA-256 (первые 8)
YOLO26n	yolo26n.pt	Ultralytics assets v8.4.0	9b09cc8b
Faster R-CNN	fasterrcnn_resnet50_fpn_v2...	PyTorch COCO_V1	dd69338a

Программные версии

Пакет	Версия
Python	3.12.13
ultralytics	8.4.150
opencv	4.11.0
pycocotools	2.0.11
polars	1.44.2

Среда выполнения: Kaggle GPU T4×2. Использованы Python, PyTorch/torchvision, Ultralytics, OpenCV и pycocotools.